

# 채권시장과 금리시장 지표에 기반 한 외환시장 환율예측 연구: 인공지능 활용의 실증적 증거

임현욱

연세대학교 투자정보공학과  
(nooklim@yonsei.ac.kr)

정승환

연세대학교 산업공학과  
(jsh0331@yonsei.ac.kr)

이희수

세종대학교 경영학과  
(heesoo@sejong.ac.kr)

오경주

연세대학교 산업공학과  
(johanoh@yonsei.ac.kr)

본 연구는 채권시장과 금리시장의 지표를 이용한 외환시장 환율예측 모델을 만드는데 있어 어떤 인공지능 방법론이 가장 적합한지 밝혀내는데 그 목적이 있다. 채권시장의 대표 상품인 국고채와 통안채는 위험회피 상황이 올 때 대규모로 매도되어지고 그런 경우 환율이 상승하는 모습을 자주 보여주었고, 금리시장에서 통화스왑 (Cross Currency Swap) 가격은 달러 유동성 문제가 생길 때 주로 하락하였으며, 그 움직임은 환율의 상승에 직간접적인 영향을 미쳐온 점 등을 고려하면, 채권시장과 금리시장에서 거래되는 상품의 가격과 움직임은 외환시장에도 직간접적인 영향을 주고 있으며, 세 시장 사이엔 상호 유기적이고 보완적인 관계가 있다고 볼 수 있다. 하지만, 지금까지 많은 연구들이 거시적인 지표를 기반으로 한 환율예측 연구에 집중되어 왔으며, 실제로 채권시장과 금리시장 지표를 활용하여 외환시장의 환율을 예측하는 시도는 아직 활발히 진행되고 있지 않은 상황이다. 본 연구는 채권시장 지표와 금리시장 지표를 기반으로, 비선형데이터 분석에 적합한 인공신경망(Artificial Neural Network) 모델과, 선형데이터 분석에 적합한 로지스틱 회귀분석 (Logistic regression), 그리고 비선형/선형데이터 분석에 활용 가능한 의사결정나무 (Decision Tree)를 각각 사용하여 환율예측 모델을 만들고 그 수익률을 비교하여 어떤 모델이 가장 외환시장 환율 예측을 하는데 적합한지 알려준다. 본 연구를 통해 주식시장, 금리시장, 오일시장, 그리고 외환시장 환율 등 비선형적 시계열 데이터 분석에 많이 사용되어진 인공신경망 모델이 채권시장과 금리시장 지표를 기반으로 한 외환시장 환율예측 모델에 가장 적합한 방법론을 제공하고 있다는 것을 증명하였다. 각각 독립적인 연구가 진행되어 왔던 채권시장, 금리시장, 그리고 외환시장의 지표들 사이의 상관관계를 밝히고 상호 유기적인 움직임을 증명하는 것은 단순히 외환시장 트레이더들에게 새로운 트레이딩 모델을 제시하는 것뿐만 아니라 금융시장 전체의 효율성을 증가시키는데 기여 할 것이라 기대한다.

## 1. 개요

금융시장을 구성하는 여러 시장 중 채권시장, 금리시장, 그리고 외환시장은 각각의 독립적인 시장인 동시에 상호 영향을 주고받는 유기적인 관계에 있다. 예를 들어, 우리나라 채권시장의 대표적 안전자산이자 국내외 투자자들에게 선호되는 국고채와 통안채는 위험 선호 시기에는 안정적인 매수 흐름을 이어가다가 위험 회피상황이 오면 공격적인 매도가 일어나게 되며, 그 공격적인 매도는 외환시장의 달러/원 환율에 상승 신호로 작용하여 달러 매수를 촉발시키게 된다. 우리나라 금리시장의 대표상품인 이자율스왑 (IRS, Interest Rate Swap)도 기본적으로 이자율이 상승하면 그 나라 통화의 투자매력도를 상승시켜 통화를 절상시키는 기능이 있으며, 반대로 이자율이 하락하면 그 나라 통화의 투자매력도를 감소시켜 통화를 절하시키는 기능이 있다. 또한 통화스왑 (CCS, Cross Currency Swap)의 경우 평소에는 기본적으로 이자율스왑의 흐름을 따라가다가, 달러 유동성 문제가 부각될 때는 통화스왑 가격이 하락하는 모습을 보이면서 달러/원 환율을 상승시키는 작용을 하다가, 달러 유동성 문제가 해결되면 통화스왑 가격이 상승하면서 달러/원 환율의 하락 요인이 되곤 한다.

이렇게 채권시장, 금리시장, 외환시장은 상호 유기적인 관계를 이어가며 상호 영향을 미치고 있음에도 불구하고, 지금까지 많은 외환시장 환율예측과 모델링에 대한 연구는 주로 GDP, 경상수지 흑자/적자, 인플레이션 등 거시경제적인 지표를 독립변수로 사용하여 이루어져 왔으며, 실제로 채권시장과 금리시장 지표를 활용하여 외환시장의 환율을 예측하는 시도는 아직 활발히 진행되고 있지 않은 상황이다. 본 연구에서는 채권시장과 금리시장의 지표를 이용한 외환시장 환율예측 모델을 만드는데 있어 어떤 인공지능 방법론이 가장 적합한 지 밝히려 한다. 채권시장 지표와 금리시장 지표를 기반으로, 비선형데이터 분석에 적합한 인공신경망(Artificial Neural Network) 모델과, 선형데이터 분석에 적합한 로지스틱 회귀분석(Logistic regression), 그리고 비선형/선형데이터 분석에 활용 가능한 의사결정나무(Decision Tree)를 각각 사용하여 환율예측 모델을 만들고 그 수익률을 비교하여 어떤 모델이 가장 외환시장 환율 예측을 하는데 적합한지 알아내는 데에 본 연구의 목적이 있다. 본 논문의 구성은 다음을 따른다. 2장 연구배경에서는 외환시장 환율예측에 관해 과거에 어떠한 관련 연구들이 진행되었는지 서술하고, 3장 연구방법에서는 외환시장 환율 예측모델을 만들기 위한 방법론들을 서술하였다. 4장 실증분석에서는 채권시장과 금리시장의 상품가격 데이터와 분석 방법론을 활용하여 분석한 내용을 서술하였고, 5장 결론 및 제언에서는 본 연구 실험의 결과 정리 및 향후 연구 주제를 제시한다.

## 2. 연구배경

외환시장 환율은 전형적인 시계열 데이터이면서, 날씨와 주식시장 데이터처럼 비선형적인 모습을 보인다. Grassberger and Procaccia (2004)이 밝힌 것처럼 외환시장 환율과 같은 시계열적인 데이터는 정리되어 있지 않고 임의적으로 보이지만, 그 안에서 상호 연결적이고 일정한 패턴이 보이는 카오스적 행동 (Chaotic Behavior)을 보인다 (Wang and Liu, 2013). 카오스적 행동을 보이는 비선형 데이터를 분석하기 위해서는 여러 인공지능 방법론 중 어떤 방법론이 적합한지를 밝혀내는 것이 중요하다. 선행연구를 통해 인공신경망(Artificial Neural Networks)은 주식시장의 주가예측에 사용 (Kim and Oh, 2004) 되어 온 것 뿐 만 아니라 이자율 시장 예측 (Oh and Han, 2000; Lahmiri, 2016), 유가 예측 (Lahmiri, 2016), 그리고 외환시장 환율 예측 (Huang et al., 2004; Lahmiri, 2017; Evans et al., 2013; Stoke and Abou.Zaid, 2012)에도 사용되어 온 것을 알 수 있었다. 본 연구를 통해 인공신경망이 다른 인공지능 방법론 보다 비선형적이고 시계열적인 외환시장 환율 데이터를 분석하는데 적합한지를 알아보려 한다.

또한, 환율을 목적변수로 하고 어떤 독립변수를 사용할 건지에 대한 결정도 올바른 방법론을 논하기 전에 선행되어야 할 사안이다. 앞에서 기술 한 것처럼 지금까지 많은 환율 예측에 관한 연구는 거시 경제적 지표를 독립변수로 사용하여 이루어져 왔다. Fabian U.Fuchs (2020)의 연구에서 수출입 관련 외환위험 해정을 위한 환율 예측에 있어서 거시 경제적 지표들을 사용한 것이 그 예이다. 하지만, 본 연구에서는 채권시장과 금리시장의 상품가격이 외환시장의 환율과 밀접한 정보 교류와 상호작용을 하고 있다는 사실을 토대로, 채권시장, 금리시장 상품 가격을 새로운 독립변수로 하여, 목적변수인 달러/원 환율을 예측하고자 한다.

### 3. 연구방법

외환시장 환율 데이터를 분석하기 위하여 의사결정나무, 로지스틱 회귀분석, 그리고 인공신경망의 3가지 방법론을 활용하였다.

#### 3.1 로지스틱 회귀분석 (Logistic regression)

인공지능 방법론 중 로지스틱 회귀분석은 종속변수가 이분형 데이터일 때 주로 쓰이는 통계적 방법론이다. 따라서 선행연구들에서는 주가의 상승하락을 예측하는 등의 이분형 예측모델을 구축할 때 많이 사용되었다 (Lee et al., 2019; Cho et al., 2020). 로지스틱 회귀분석은 회귀 모델이기 때문에 비교적 선형성을 띠는 데이터에게 적합한 방법론이다.

본 연구의 실증분석을 위해 IBM SPSS Statistics 25를 사용했다. 로지스틱 회귀분석은 입력한 변수를 모두 사용하도록 설정하여 실증분석을 진행하였으며, 학습 (training) 데이터와 검증 (testing) 데이터는 의사결정나무에서와 동일하게 각각 1년 6개월과 6개월로 설정하였다.

#### 3.2 의사결정나무 (Decision Tree)

인공지능 방법론 중 의사결정나무는 데이터들을 이용하여 분류모형을 만드는 기법이다. 분류모형이 나뉘어가지 형태를 보이기 때문에 의사결정나무라고 불린다 (Kim and Oh, 2012). 의사결정나무는 종속변수를 가장 잘 설명할 수 있는 독립변수를 선정하고, 그 변수를 기준으로 종속변수를 결정하기 위한 하위 가치를 설정한다. 그리고 그 다음 종속변수를 잘 설명하는 독립변수를 하위 가치로 추가하는 방식으로 의사결정나무는 구축된다.

본 연구의 실증분석을 위해 IBM SPSS Statistics 25를 사용했다. 다양한 의사결정나무의 성장방법 중 CHAID 방법을 활용하였다. 최대 나무 깊이는 3으로 설정하였으며, 부모 노드는 최소 케이스 수를 100으로, 자식 노드는 최소 케이스 수를 50으로 설정하였다. 데이터의 경우 학습 (training) 데이터는 1년 6개월로 설정하였고, 검증 (testing) 데이터는 6개월로 설정하였다.

#### 3.3 인공신경망 (Artificial neural network)

인공지능 방법론 중 인공신경망은 종속변수를 구하기 위한 독립변수들의 구조가 신경망 구조를 띠는 기법이다 (Oh et al., 2011). 인공신경망의 구조는 독립변수와 종속변수 사이에 여러 개의 노드가 존재하고, 독립변수와 노드 간, 그리고 노드들과 종속변수 간에 가중치가 각각 존재하기 때문에, 독립변수와 종속변수 간의 모델을 설명하기 어려운 방법론이다.

본 연구의 실증분석을 위해 IBM SPSS Statistics 25를 사용했다. 인공신경망의 경우는 초기 값을 고정해주지 않으면 매번 다른 결과 값이 도출되기 때문에, 결과의 일관성을 위해 초기 값을 50으로 고정해주었다. 공변량의 조정은 표준화 방식을 택하였고, 신경망 설계는 은닉층에서의 노드 수를 최소 1에서 최대 50 중 자동으로 설정하도록 하였다. 인공신경망의 경우 검증 (validation) 데이터도 필요하기 때문에, 의사결정나무 방법론과 로지스틱 회귀분석 방법론에서의 학습 (training) 데이터를 학습 데이터와 검증 데이터로 나누어주었다.

따라서 학습 (training) 데이터는 1년, 검증 (validation) 데이터는 6개월, 검증 (testing) 데이터는 6개월로 설정하였다.

## 4. 실증 분석

실증 분석을 위해 2008년 1월부터 2020년 12월까지 12년 동안의 달러/원 환율, 1Y IRS 금리와 1Y CCS 금리, 10Y IRS 금리와 10Y KTB 수익률, 그리고 10Y 본드 스왑 스프레드 (IRS-KTB)를 활용했다. 사용된 데이터는 모두 일별 종가를 사용하였다. (Table 1)

<Table 1 > Data used in the Experiment

Data	Period (yyyy/mm/dd)	Source
USDKRW exchange rates	2008/01/01-2020/12/31	Yonhap Infomax
1Y IRS rates	2008/01/01-2020/12/31	Bloomberg
1Y CCS rates	2008/01/01-2020/12/31	Bloomberg
10Y IRS rates	2008/01/01-2020/12/31	Bloomberg
10Y KTB yields	2008/01/01-2020/12/31	Bloomberg
10Y Bond Swap Spread (IRS - KTB)	2008/01/01-2020/12/31	Bloomberg

### 4.1 변수 선정

#### 4.1.1 목적변수

목적변수인 달러/원 환율 증가 데이터는 금융정보 전문 업체 이자 연합뉴스의 자회사인 연합 인포맥스에서 수집하였다. 연합 인포맥스는 매일 그날의 달러/원 환율의 시가/고가/저가/종가 데이터를 서울외국환중개 (SMBS; Seoul Money Brokerage Services)에서 받아서 정보 단말기를 통해 구독자에게 제공한다. 국내 달러/원 스왑 시장의 영업시간은 서울시간 오전 9시부터 오후 3시 30분까지이다. 그러므로 달러/원 환율의 증가는 오후 3시 30분에 서울외국환중개 로이터 페이지에 고시되고, 동시에 연합 인포맥스 단말기에 고시된다.

#### 4.1.2 독립변수

##### 4.1.2.1 금리시장 지표

독립변수로는 우선 원화 금리시장의 1Y IRS 금리와 1Y CCS 금리를 사용했다. IRS (Interest Rate Swap) 또는 이자율스왑은 금리변동위험 헤지 및 차입비용 절감 등을 위하여 거래당사자 간에 원금 교환 없이 정기적 (3개월)으로 변동금리와 고정금리를 교환하는 거래를 말한다. 여기서의 변동금리는 91일물 CD금리를 말하며, 고정금리는 IRS 거래금리를 말한다. 거래단위와 만기는 제한이 없지만, 통상 100억 원 단위로 거래를 하며 만기 1년에서 5년 거래가 주를 이루지만, 만기 10년까지의 거래도 시장조성에 큰 문제 없이 이루어지고 있다. 1년 IRS 금리와 같은 단기 이자율스왑 금리는 한국은행 정책금리 변동에 민감하게

움직이는 특성이 있는데, 기본적으로 현지통화의 이자율이 높아지면 해당통화의 투자매력도가 상승하여 달러에 대한 해당통화의 절상 (달러/원 환율하락)을 야기시킬 수 있으며, 현지통화의 이자율이 낮아지면 해당통화의 투자매력도가 하락하여 달러에 대한 해당통화의 절하 (달러/원 환율 상승)를 이끌게 된다. CCS (Cross Currency Swap) 또는 통화스왑은 거래 당사자 간에 서로 다른 통화를 교환하고 일정기간 후 원금을 재 교환하기로 하는 약정을 말하며, 계약기간 중 이자를 정기적으로 (원화 CCS의 경우 매 6개월) 교환하고 만기시점에 처음 원금을 교환했을 때 적용했던 환율로 다시 원금을 교환하는 거래를 말한다. 유동성은 외환 스왑과 만기가 겹치는 만기 1년 거래가 가장 높고, 2년부터 10년까지의 유동성은 이자율스왑에 비해 현저히 낮은 편이다.

일반적으로 우리나라 시장에서 달러조달의 문제가 생길 때 달러를 조달 할 수 있는 통화스왑 Receive 수요가 증가해 통화스왑 금리가 하락하며, 그런 CCS 가격의 움직임은 외환시장에서 달러 매수의 신호로 인식돼 많은 경우 달러/원 환율이 상승하는 모습을 보여 왔다. 이후 달러조달의 문제가 해결되었을 경우 CCS Pay 수요가 증가해 통화스왑 금리가 상승하며, 그런 CCS 가격의 움직임은 외환시장에서 달러 매도의 신호로 인식돼 많은 경우 달러/원 환율이 하락하는 모습을 보여 왔다. 본 연구에서는 가장 유동성이 좋은 1년 IRS 금리와 1Y CCS금리를 독립변수로 사용하였다.

#### 4.1.2.2 채권시장 지표

추가적인 독립변수로써는 채권시장의 10Y KTB 수익률을 사용하였다. 국고채 수익률은 평소에는 수요와 공급의 법칙에 따라 움직이다가 위험 회피 현상이 오면 투자자는 국고채 매도를 통해 자산 보유를 줄이게 되며, 그러한 국고채 가격의 하락 (국고채 수익률 상승)은 외환시장에서 달러 매수의 신호로 인식돼 달러/원 환율이 상승하는 모습을 보인다. 이후 시장이 안정되면 다시 자산을 되사려는 투자자들의 국고채 매수 움직임으로 인해 국고채 가격은 상승 (국고채 수익률 하락)하게 되며, 이는 외환시장에서 달러 매도의 신호로 인식돼 달러/원 환율이 하락하는 모습을 보이게 된다.

#### 4.1.2.3 금리시장과 채권시장의 동시지표: 본드 스왑 스프레드

채권시장의 국고채 수익률과 외환시장의 달러/원 환율 간의 일정 수준의 상관관계가 있다고 하더라도, 기본적으로 국고채 수익률은 IRS 금리와 움직임을 같이 하며 IRS 금리에 수렴하거나 IRS 금리를 국고채 수익률에 수렴시키는 관계를 가지고 있다. 그러므로 본 실험에서 환율을 예측하는데 있어 금리시장/채권시장 독립변수로 사용한 IRS와 KTB 금리에 더해서, 좀 더 외환시장의 달러/원 환율과 상관관계가 높은 변수인 본드 스왑 스프레드 가격 (IRS 금리에서 KTB 수익률을 뺀 가격)을 제 5의 독립변수로 사용하려 한다. 본드 스왑 스프레드는 IRS 금리와 KTB 수익률의 차이를 말한다. 여기서 IRS 금리란 앞에서 서술한 대로 변동금리와 교환되는 고정금리를 말하는데, 이때 변동금리는 91일물 CD금리를 말하며, CD 금리는 은행의 신용이 반영된 금리이다. 그러므로 CD금리와 교환되는 IRS금리도 마찬가지로 은행의 신용이 반영된 금리인 것이 된다. KTB 수익률은 정부가 발행한 채권으로 정부의 신용이 반영된 금리이다. 이론적으로는 정부의 신용이 은행보다 높으니 국고채 수익률이 IRS 금리보다 낮은 것이 일반적이거나, 우리나라의 경우는 정부의 활발한 재정정책으로 국고채 발행이 수요보다 많은 점, 그리고 은행권의 변동금리 대출이 고정금리 대출보다 많아 은행권

의 IRS 리시브 수요가 많고, 보험사들의 듀레이션 관리를 위한 IRS 리시브 수요가 많은 이유로 대개 국고채 수익률이 IRS 금리보다 높게 형성되어 있다. 즉, 우리나라의 본드 스왑 스프레드 (IRS 금리 - KTB 수익률)는 대개 음(-)의 상태로 지속되어 왔다. 만약 시장에 위험회피 현상이 나타나 투자자들이 KTB 매도를 단행하게 되면 국고채 수익률은 IRS 금리보다 더 빨리 상승하게 되며, 음(-)의 본드 스왑 스프레드는 더욱 확대 (Bond Swap Spread Widening) 되게 된다. 이 경우 외환시장의 달러/원 환율은 본드 스왑 스프레드의 확대를 달러 매수의 신호로 여기게 되어 달러/원 환율은 상승하게 되며, 이 후 시장이 안정되어 투자자들의 KTB 매수 심리가 회복되면 IRS 금리보다 KTB 수익률은 더 빨리 하락하게 되고, 이는 본드 스왑 스프레드의 축소 (Bond Swap Spread Tightening)로 이어지며, 외환시장은 이를 달러 매도 신호로 해석해 달러/원 환율은 하락하게 된다.

## 4.2 인공지능 방법론 간 Hit Ratio 비교

유의미한 예측모델을 만들기 위한 방법론으로 인공신경망 (ANN), 로지스틱 회귀분석 (LR), 의사결정나무 (DT)를 활용하여 진행하였고, 이에 대한 hit ratio를 확인하였다. Hit ratio는 예측모델의 성능을 판단할 때 자주 사용되는 지표이지만, 비선형적이고 시계열적인 데이터를 다루는 예측모델에는 단순 적용하기에는 여러 가지 제약점이 있다. 이는 실제 트레이딩에 있어 높은 Hit Ratio를 가진 트레이더가 반드시 실제 높은 수익을 올리지는 않으며, Hit Ratio는 낮아도 리스크관리 원칙 아래 시장의 큰 흐름에 적절히 대응해 거래하는 트레이더가 때로는 더 큰 수익을 올리는 경우가 많다는 점과 맥을 같이 한다. 그러므로 본 연구에서는 Hit Ratio의 절대 레벨평가 보다는, 비선형적이고 시계열적인 외환시장, 채권시장, 금리시장의 데이터를 다루는데 있어 어떤 인공지능 방법론이 가장 적합한지를 찾는데 Hit Ratio를 사용하려 한다. Table 2에서 보이는 대로 ANN 방법론이 51%에 가까운 Hit Ratio를 보이면서 다른 방법론의 Hit Ratio와 비교하여 가장 좋은 성능을 보여주었다. 다음 장에서는 각 인공지능 방법론으로 만들어진 트레이딩 모델로 트레이딩 시뮬레이션을 수행해 보고 각 모델 간의 수익률을 비교해 보려 한다.

<Table 2> Hit Ratio of the Trading Models

Hit ratio	ANN	LR	DT
Set 1	55.81%	44.19%	43.41%
Set 2	47.97%	47.97%	47.15%
Set 3	61.72%	57.81%	64.84%
Set 4	48.36%	57.38%	57.38%
Set 5	44.80%	44.80%	44.80%
Set 6	50.41%	49.59%	49.59%
Set 7	60.80%	53.60%	60.00%
Set 8	47.97%	47.97%	47.15%
Set 9	58.87%	41.13%	58.87%

Set 10	56.20%	56.20%	56.20%
Set 11	50.00%	52.42%	50.00%
Set 12	45.90%	54.10%	45.90%
Set 13	53.17%	51.59%	48.41%
Set 14	47.93%	47.93%	45.45%
Set 15	45.60%	44.80%	54.40%
Set 16	50.82%	50.82%	50.82%
Set 17	56.20%	56.20%	38.02%
Set 18	47.11%	47.11%	47.11%
Set 19	52.03%	52.03%	52.03%
Set 20	47.90%	47.90%	47.90%
Set 21	48.76%	47.93%	52.07%
Set 22	54.47%	50.41%	56.91%
Set 23	39.34%	39.34%	39.34%
Average	50.96%	49.70%	50.34%

### 4.3 예측모델 실험

인공지능 방법론인 ANN, LR, DT를 활용하여 달러/원 환율의 일별 예측 값을 얻어내고, 그 예측 값을 실제 과거 데이터에 적용해서 거래 수익률을 구하는 트레이딩 모델 시뮬레이션을 수행하였다. 트레이딩 모델은 매일 오후 3시 30분 그날의 달러/원 스왑 시장이 마감 된 후 그날의 1Y IRS, 1Y CCS, 10Y IRS, 10Y KTB, 그리고 10Y IRS-KTB 종가를 가지고, ANN, LR, DT의 3가지 인공지능 방법론을 통해 달러/원 환율을 매입 할 것 인지 또는 매도 할 것인지에 대한 거래신호를 만든다. 그런 후 2009년 1월부터 2020년 12월까지 실제 달러/원 환율 데이터에 적용해 해당 트레이딩 모델의 거래 수익을 계산한다. 트레이딩 시뮬레이션을 수행하는데 있어서 다음과 같은 트레이딩 룰을 적용하였다.

1 단계. 만약 인공지능 모델의 예측 값이 testing 기간 동안 1이 나오면 매수신호로 달러/원을 매수한다. 만약 0일 경우 매도 신호로 달러/원을 매도한다.

2 단계. 달러/원 매수, 매도의 시점과 가격은 그날의 달러/원 스왑 종가이다. 달러/원 시장의 풍부한 유동성과 스왑 시장 마감 후 곧바로 이어지는 원화 차익결제 선물환 시장 (NDF, Non-Deliverable Forward) 시장의 연속성을 감안할 때, 그날의 종가 수준의 달러/원 매매는 일반적으로 가능하다.

3 단계. 트레이딩 모델의 수익을 계산 시, 포지션을 유지하고 있는 기간 동안에는 적절한 스왑 포인트 (Swap point)를 적용하여 거래 수익계산을 좀 더 정확하게 한다. 스왑 포인트 계산을 위하여 사용되어진 원화 이자율은 한국은행 기준금리이며, 달러 이자율은 FOMC's Target Federal Funds rate 이다. (Federal Reserve System)

스왑 포인트는 다음과 같은 공식으로 구한다.

$$\text{스왑 포인트} = \text{스왑 가격} \times ((1 + \text{원화이자율}) / (1 + \text{달러이자율}) - 1)$$

4 단계. 달러/원 포지션은 최고 5개까지로 제한한다. 거시 경제적 영향을 많이 받는 환율데이터 특성상 장기간 같은 방향의 신호가 나오는 경우가 많은데 이 경우엔 영원히 포지션을 누적 시키는 것은 현실적이지 않으므로 1주일 (5 trading days)로 포지션 누적을 제한한다.

5 단계. 트레이딩 수익률을 계산하는데 사용되는 투자금액은 당해의 평균 환율로 한다. 포지션이 누적되는 동안의 투자금액은 원화금리와 달러금리의 차이인 스왑 포인트로 계산되어 총 누적 수익/손실 금액에서 가감하는 형태로 반영한다.

6 단계. 연별 수익률과 연별 수익금액을 구하기 위해 매년 초 트레이딩 포지션을 일으키고 매년 말에 남은 포지션이 있다면 청산한다.



&lt;Table 3&gt; Empirical study result

Year	Amt Invested	ANN		LR		DT	
		P/L	Annualize d Return	P/L	Annualize d Return	P/L	Annualize d Return
2009	1204.46	88	7.3%	189	15.7%	- 42	- 3.5%
2010	1156.00	494	42.7%	- 1,074	- 92.9%	- 860	- 74.4%
2011	1108.18	156	14.1%	672	60.7%	674	60.8%
2012	1126.76	- 26	- 2.3%	- 546	- 48.5%	- 450	- 39.9%
2013	1095.04	21	1.9%	- 246	- 22.4%	42	3.8%
2014	1053.12	699	66.4%	265	25.1%	699	66.4%
2015	1131.52	- 437	- 38.6%	312	27.6%	- 575	- 50.9%
2016	1160.41	- 171	- 14.8%	182	15.7%	- 460	- 39.6%
2017	1130.48	- 561	- 49.7%	- 573	- 50.7%	- 68	- 6.0%
2018	1100.58	42	3.8%	- 52	- 4.7%	- 782	- 71.1%
2019	1166.07	- 224	- 19.2%	- 302	- 25.9%	- 140	- 12.0%
2020	1180.59	323	27.4%	361	30.6%	115	9.8%
Position Limit		Total P/L	Average Return	Total P/L	Average Return	Total P/L	Average Return
5		402.41	3.245%	- 812.06	- 5.818%	- 1847.67	- 13.054%

&lt;Table 4&gt; MSB and KTB Yields in 2009-2020

Year	1Y MSB	2Y MSB	3Y KTB	10Y KTB
2009	2.98%	3.84%	4.05%	5.17%
2010	3.03%	3.66%	3.71%	4.77%
2011	3.55%	3.71%	3.62%	4.20%
2012	3.12%	3.16%	3.13%	3.44%
2013	2.66%	2.75%	2.79%	3.28%
2014	2.45%	2.53%	2.59%	3.19%
2015	1.70%	1.76%	1.79%	2.30%
2016	1.44%	1.45%	1.44%	1.75%
2017	1.55%	1.73%	1.80%	2.28%
2018	1.86%	2.05%	2.10%	2.50%
2019	1.54%	1.55%	1.53%	1.70%
2020	0.96%	1.05%	1.07%	1.50%
Average	2.24%	2.44%	2.47%	3.01%

위의 조건으로 트레이딩 시뮬레이션을 해본 결과, Table 3에서와 같이 ANN의 수익률이 3.245%로 LR, DT에 비해 더 나은 모습을 보여주었다. ANN을 활용해 채권시장, 금리시장 지표를 독립변수로 만든 달러/원 트레이딩 모델의 수익률 3.245%는 동 기간 안전자산 수익률인 만기 1년의 통안채, 만기 2년의 통안채, 만기 3년의 국고채, 그리고 만기 10년의 국고채의 수익률 (Table 4)을 상회하며, 이는 달러/원 환율 트레이딩 예측모델에는 인공지능 방법론 중 ANN이 적합하다는 것을 보여준다.

## 5. 결론

달러/원 환율 예측연구에 있어서 거시 경제적 지표를 사용하는 연구 이외에 금리시장이나 채권시장의 지표를 사용하여 인공지능 기법을 활용한 연구는 많이 부족한 상황이다. 본 연구에서는 목적변수인 외환시장 환율을 예측하는데 있어서 금리시장의 지표인 이자율스왑 (IRS)과 통화스왑 (CCS) 지표를 독립변수로 사용하였고, 채권시장의 지표인 국고채 수익률을, 그리고 금리와 채권시장의 공통 지표인 본드 스왑 스프레드 (Bond Swap Spread)를 독립변수로 사용하였다는 점에서 의미가 있다. 더 나아가 본 연구는 인공지능 방법론에 있어서 시계열적인 외환시장 환율을 예측하는 경우엔 선형적 데이터 분석에 많이 사용되어온 로지스틱 회귀분석 (Logistic Regression) 이나 비선형적/선형적 데이터 모두에서 사용되어 졌던 의사결정나무 (Decision Tree)를 활용하는 것 보다는 비선형적 데이터 분석에 적합한 인공신경망(ANN, Artificial Neural Network)이 활용하는 것이 적합하다는 것을 보여주었다. 본 연구는 실제로 달러/원 환율을 거래하는 외환 트레이더에게는 금리시장과 채권시장의 지표들이 외환시장의 선행지표가 될 수 있음을 제안하였으며, 이는 금융시장 속 서로 각자 다른 기능을 가진 외환시장, 금리시장, 채권시장이 서로 유기적이고 상호 보완적인 관계에서 움직이고 있다는 것을 증명하였다.

본 연구에서 사용된 금리시장, 채권시장의 변수들은 분명 외환시장 환율과 상관관계가 있는 변수들이지만, 해당 변수를 사용해 ANN을 활용하여 만든 트레이딩 모델의 수익률이 안전자산인 통안채와 국고채 수익률을 조금 넘어서는 수준의 수익률 이라는 점은 향후 연구에서는 좀 더 개선해야할 부분이라고 생각한다. 이를 위해 본 연구에서 얻어진 연구 성과, 즉, 환율예측에는 인공지능 방법론 중 ANN 사용이 적합하다는 사실에 더해서, 본 연구에서 사용되어진 금리시장, 채권시장의 독립변수 이외의 다른 독립변수를 찾아서 ANN을 통해 만든 달러/원 환율 트레이딩 모델의 수익률을 좀 더 높여보려 한다. 또한, 달러/원 환율 트레이딩 모델 시뮬레이션 수행 시 포지션 한도를 다양화하고 증가시켜서 그 수익률의 변화를 살펴보려 하며, 실제 거래에서 반드시 지켜야할 일중, 주중, 월중, 연중 손실 한도(Daily, Weekly, Monthly, Yearly Stop Loss Limit)도 트레이딩 모델에 적용하여 좀 더 정밀한 트레이딩 모델을 만들고자 한다.

## 참고문헌

- Grassberger, P., and I. Procaccia, "Measuring the strangeness of strange attractors." *The theory of chaotic attractors*. Springer, New York, NY, (2004), 170~189.
- Wang, X., Z. Liu, and M. Wang, "The correlation fractal dimension of complex networks." *International Journal of Modern Physics C*, Vol.24, 2013, 1350033.
- Kim, T. Y., K. J. Oh, C. Kim and J. D. Do, "Artificial neural networks for non-stationary time series," *Neurocomputing*, Vol.61, 2004, 439~447.
- Oh, K. J., and I. Han, "Using change-point detection to support artificial neural networks for interest rates forecasting," *Expert systems with applications*, Vol.19, 2000, 105~115.
- Lahmiri, S., "Interest rate next-day variation prediction based on hybrid feedforward neural network, particle swarm optimization, and multiresolution techniques," *Physica A: Statistical Mechanics and its Applications*, Vol.444, 2016, 388~396.
- Lahmiri, S. "A variational mode decomposition approach for analysis and forecasting of economic and financial time series." *Expert Systems with Applications*, Vol.55, 2016, 268~273.
- Huang, W., K. K. Lai, Y. Nakamori, and S. Wang, "Forecasting foreign exchange rates with artificial neural networks: A review." *International Journal of Information Technology & Decision Making*, Vol.3, 2004, 145~165.
- Lahmiri, S. "Modeling and predicting historical volatility in exchange rate markets." *Physica A: Statistical Mechanics and its Applications*, Vol.471, 2017, 387~395.
- Evans, C., K. Pappas, and F. Xhafa, "Utilizing artificial neural networks and genetic algorithms to build an algo-trading model for intra-day foreign exchange speculation." *Mathematical and Computer Modelling*, Vol.58, 2013, 1249~1266.
- Stokes, A. and A. S. Abou.Zaid, "Forecasting foreign exchange rates using artificial neural networks: a trader's approach." *International Journal of Monetary Economics and Finance*, Vol.5, 2012, 370~394.
- Fuchs, F., "Macroeconomic determinants of foreign exchange rate exposure" *The Quarterly Review of Economics and Finance*, 2020.
- Lee, H. S., S. H. Jeong, and K. J. Oh, "A study on the prediction of korean NPL market return." *Journal of Intelligence and Information Systems*, Vol.25, No.2(2019), 123~139.
- Cho, D. H., H. S. Ryou, S. H. Jeong, and K. J. Oh, "Using AI to develop forecasting model in IPO market." *Journal of the Korean Data And Information Science Society*, Vol.31, No.3(2020), 579~590.
- Kim, H. H. and K. J. Oh, "Using rough set to develop the optimization strategy of evolving time-division trading tin the futures market," *Journal of the Korean Data & Information Science Society*, Vol.23, No.5(2012), 881~893.
- Oh, K. J., T. Y. Kim, K. W. Jung and C. H. Kim, "Stock market stability index via linear and neural network autoregressive model," *Journal of the Korean Data & Information*

*Science Society*, Vol.22, No.2(2011), 335~351.

Federal Reserve System <https://www.federalreserve.gov/monetarypolicy/openmarket.htm>  
(accessed on 01 June 2021)